

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский
Нижегородский государственный университет им. Н.И. Лобачевского»
(ННГУ)

Институт информационных технологий, математики и механики

ОТЧЕТ ПО ЛАБОРАТОРНОЙ РАБОТЕ
на тему:
**«Сравнительный анализ алгоритмов сортировки
k-merge и d-heap»**

Выполнили: студент группы
3822Б1ФИ2

_____/ Хохлов А.Д./
Подпись

Проверил: ассистент кафедры АГДМ,
_____/ Уткин Г.В./

Подпись

Нижний Новгород
2024

Содержание

Введение.....	3
Цель	3
1. Описание алгоритмов.....	4
1.1.1 Сортировка к-слиянием	4
1.1.2 Временная сложность сортировка к-слиянием.....	4
1.2.1 Сортировка d-кучей.....	5
1.2.2 Временная сложность сортировки d-кучей.....	5
2 Описание алгоритмов программы	6
2.1 Сортировка к-слиянием	6
2.2 Сортировка d-кучей.....	7
3 Проведенные эксперименты.....	10
4 Сравнение алгоритмов	14
5 Вывод	15

Введение

Лабораторная работа направлена на изучение и реализацию двух алгоритмов: к-слияние и сортировка на д-кучах.

Цель

Целью данной работы является реализация сортировки 4-слиянием и 3-кучи. После чего необходимо проанализировать сложности алгоритмов, а также сравнить их экспериментально. Первая программа должна читать из файла входную информацию и создавать два новых, каждый из которых должен содержать результаты работы соответствующего алгоритма и время его работы. Вторая программа предназначена для проведения экспериментов, параметры для массива данных будут также считываться из файла, а время работы алгоритмов должны записываться в новые, соответствующие два файла.

Задачи:

1. Реализовать структуру данных d-куча.
2. Реализовать сортировку кучей.
3. Реализовать алгоритм сортировки к-слиянием.
4. Написать программу, проверяющую работу алгоритмов, зафиксировать результат и время их работы
5. Провести эксперименты для тестирования программы на различных входных данных.

Эксперименты будут проводится на машине со следующими характеристиками:

1. Процессор - 10th Gen Intel(R) Core(TM) i7-10700K 2.90 GHz
2. Оперативная память - 32,0 ГБ (доступно: 31,7 ГБ)
3. Тип системы - 64-разрядная операционная система, процессор x64

1. Описание алгоритмов

1.1.1 Сортировка к-слиянием

Сортировка к-слиянием, как и быстрая сортировка, является алгоритмом типа «разделяй и властвуй». Ее рекурсивная реализация состоит в разбиении массива на k приблизительно одинаковых частей, их сортировкой с последующим объединением отсортированных фрагментов. Для этого используются две процедуры: $\text{SORT_MERGE}(a, i, j, k)$ и $\text{MERGE}(a, i, m, j)$.

$\text{SORT_MERGE}(a, i, j, k)$:

Если длина входного массива меньше, чем n/k , то массив сортируется пузырьком, иначе рекурсивно вызывается $\text{SORT_MERGE}(a, i + \text{step} * \text{numb}, i + \text{step} * (\text{numb} + 1) - 1, k)$, где $\text{step} = (j - i + 1) / k$, $\text{numb} = \overline{0, k}$ при условии что $\text{numb} < k - 1$. Иначе вызывается $\text{SORT_MERGE}(a, i + (k - 1) * \text{step}, j, k)$. После чего вызывается $\text{SORT_MERGE}(a, i + (k - 1) * \text{step}, j, k)$ на остатке массива. После этих действий мы получаем k отсортированных массивов, их осталось слить функцией MERGE .

В цикле вызывается $\text{MERGE}(a, i, i + \text{step} * (\text{numb} + 1) - 1, i + \text{step} * (\text{numb} + 2) - 1)$, если $\text{numb} < k - 2$. Иначе $\text{MERGE}(a, i, i + (k - 1) * \text{step} - 1, j)$.

На выходе мы получаем отсортированный массив.

1.1.2 Временная сложность сортировка к-слиянием

Для этого составим рекуррентное соотношение. Пускай $T(n)$ — время сортировки массива длины n , тогда для сортировки слиянием справедливо $T(n) = 2 * T(n/2) + O(n)$ ($O(n)$ — это время, необходимое на то, чтобы слить два массива). Распишем это соотношение:

$$T(n) = 2 * T(n/2) + O(n) = 4 * T(n/4) + 2 * O(n) = \dots = 2^l * T(w) + l * O(n)$$

Где w — число элементов, которые сортируются пузырьком.

Значит справедливо: $T(w) = O(w^2)$

$2^l = \frac{n}{w}$ w - в зависимости от n может изменяться от 1 до $k-1$ (Сортировка к-слиянием).

Таким образом, $l = \log \frac{n}{w} = \log n - \log w$. Т.к. $w = \text{const}$ для конкретного n , то $O(l) = O(\log n)$,

и аналогично для $O(2^l) = O(\frac{n}{w}) = O(n)$.

Итак, $T(n) = O(nw^2) + \log n * O(n) = O(n) + \log n * O(n) = O(n * \log n)$

Таким образом временная сложность сортировки к-слиянием будет $O(n * \log n)$.

1.2.1 Сортировка d-кучей

Сортировка кучей — алгоритм сортировки, использующий структуру данных d-куча. Это неустойчивый алгоритм сортировки с временем работы $O(n \log n)$, где n — количество элементов для сортировки, и использующий $O(1)$ дополнительной памяти.

Алгоритм сортировки:

1. Построим на базе массива a за $O(n)$ кучу для максимума.
2. Минимальный элемент находится в корне, поменяем его местами с $a[n-1]$.
3. Далее вызовем процедуру погружения для 0 элемента для поддержания свойств кучи, предварительно уменьшив размер кучи на 1. Она за $O(\log n)$ просеет $a[0]$ на нужное место и сформирует новую кучу.
4. Повторим эту процедуру для новой кучи, корень будет менять местами с $a[n-2]$.
5. Делая аналогичные действия, пока размер кучи не станет равен 1, мы будем ставить наименьшее из оставшихся чисел в конец не отсортированной части.
6. Таким образом, мы получим отсортированный массив.

1.2.2 Временная сложность сортировки d-кучей

Временная сложность сортировки d-кучей Временная сложность этого алгоритма может быть оценена на основе двух основных этапов: построения d-кучи и процесса сортировки.

Построение d-кучи требует $O(n)$ времени, что можно показать следующим образом:

- Для узлов на нижних уровнях кучи (где h близка к 0) требуется меньше времени, так как у них меньше дочерних узлов.
- Для узлов на верхних уровнях (где h близка к $\log_d(n)$) требуется больше времени, но таких узлов меньше.

В результате, суммируя время для всех узлов, мы получаем $O(n)$ для построения d-кучи. Оценка процесса сортировки:

- Производится извлечение корня кучи (минимального элемента) и последующая перестановка элементов в конце массива. Для этого корень заменяется последним элементом и происходит "погружение".
- Каждое извлечение корня занимает $O(\log_d(n))$ времени, и поскольку необходимо извлечь n элементов, это дает общее время $O(n \log_d(n))$.

Итоговая временная сложность равна $O(n \log_d(n))$.

2 Описание алгоритмов программы

2.1 Сортировка к-слиянием

В ходе данной лабораторной работы был реализован алгоритм сортировки к-слиянием следующим образом:

```
template <typename T>
void bubbleSort(std::vector<T>& a, int i, int j) {
    for (int k = i; k <= j; ++k) {
        for (int l = i; l < j - (k - i); ++l) {
            if (a[l] > a[l + 1]) {
                std::swap(a[l], a[l + 1]);
            }
        }
    }
}

template <typename T>
void MERGE(std::vector<T>& a, int i, int m, int j) {
    int n1 = m - i + 1; // Размер первой половины
    int n2 = j - m;      // Размер второй половины

    std::vector<T> b(j - i + 1); // Временный массив для слияния
    int i1 = i, i2 = m + 1; // Индексы для двух половин

    while (i1 + i2 < j + m + 2) {
        if ((i1 <= m && i2 < j + 1 && a[i1] <= a[i2]) || i2 == j + 1) {
            b[i1 + i2 - i - m - 1] = a[i1];
            i1++;
        }
        else {
            b[i1 + i2 - i - m - 1] = a[i2];
            i2++;
        }
    }

    // Копируем отсортированные элементы обратно в оригинальный массив
    for (int k = 0; k < b.size(); ++k) {
        a[i + k] = b[k];
    }
}

template <typename T>
void SORT_MERGE(std::vector<T>& a, int i, int j, int k) {
    if (j - i + 1 < k) {
        bubbleSort(a, i, j);
    }
    else {
        int step = (j - i + 1) / k;
        for (int numb = 0; numb < k; ++numb) {
            if (numb < k - 1) {
                SORT_MERGE(a, i + step * numb, i + step * (numb + 1) - 1, k);
            }
            else {
                SORT_MERGE(a, i + (k - 1) * step, j, k);
            }
        }
        for (int numb = 0; numb < k - 1; ++numb) {
            if (numb < k - 2) {
                MERGE(a, i, i + step * (numb + 1) - 1, i + step * (numb + 2) -
1);
            }
        }
    }
}
```

```

        else {
            MERGE(a, i, i + (k - 1) * step - 1, j);
        }
    }
}
}

```

Метод **bubbleSort**

Сортируем массив длины n/k пузырьком. Принимает 3 параметра: массив *a*, индекс начала сортируемой части, индекс конца сортируемой части. Последовательно обходит все элементы и сравнивает со всеми после него. Если элемент после него оказался меньше, то меняет их местами.

Метод **SORT_MERGE**

Является основной рекурсивной функцией, которая сортирует массив.

- Принимает четыре параметра: указатель на массив *a*, левую границу *i*, правую границу *j* и параметр *k*.
- Если длина массива меньше n/k ($j-i < n/k$), то:
 - Вызывается функция **bubbleSort**, сортирует данный массив пузырьком.
- Рекурсивно вызывается **SORT_MERGE** для всех массивов длины n/k .
- Рекурсивно вызывается **SORT_MERGE** для оставшихся элементов массива.
- Рекурсивно вызывается **MERGE** для отсортированных массивов длины n/k .
- Рекурсивно вызывается **MERGE** для оставшихся элементов массива.

Метод **MERGE**

Сливает два массива в один.

Рассчитывается размер первого массива $= m - i + 1$ и размер второго массива $= j - m$. Индекс первой половины $i1 = i$, второй половины $i2 = m + 1$. После чего в цикле пока сумма индексов половин меньше $j + m + 2$ если $i1 \leq m \ \&\& \ i2 < j + 1 \ \&\& \ a[i1] \leq a[i2]) \ || \ i2 == j + 1$, то в выходной массив записывается элемент первого массива, иначе элемент второго.

2.2 Сортировка d-кучей

В ходе данной лабораторной работы был реализован алгоритм сортировки с помощью d-кучи. Для этого был реализован шаблонный класс **DHeap**, в котором содержатся методы, необходимые для сортировки.

```

template<class T>
class DHeap {
private:
    std::vector<T> heap{};
    int d{};

```

```

//operations for heap
int father(int id);
int first_child(int id);
int last_child(int id);
int min_child(int id);

public:
    DHeap();
    DHeap(const int& d_, const std::vector<T>& keys); // ~build_heap
    void sift_down(int id);
    void sift_up(int id);
    void insert(T elem);
    T extract_min();
    std::vector<T> sort_d(const int& d_, const std::vector<T>& a);
    void print_heap();
};

```

Метод сортировки

```

template<class T> std::vector<T> DHeap<T>::sort_d(const int& d_, const
std::vector<T>& a)
{
    // DHeap(d_, a);
    int n = heap.size();
    std::vector<T> sort_a;

    while (n > 0)
    {
        for (int i = 0; i < n; i++)
        {
            sort_a.push_back(extract_min());
            n = heap.size();
        }
    }
    heap = sort_a;
    return sort_a;
}

```

• Принимает степень кучи `d_` и вектор `a`, который нужно отсортировать. • Создает `d`-кучу, инициализируя её с помощью конструктора `DHeap`.

• Создает пустой вектор `sort_a` для хранения отсортированных элементов.

• В цикле извлекает минимальные элементы из кучи с помощью `extract_min` и добавляет их в `sort_a`, пока куча не станет пустой.

• Возвращает отсортированный вектор `sort_a`.

Рассмотрим методы, используемые в данной реализации:

Конструктор `DHeap`:

• Принимает два параметра: `d_` (степень кучи) и `keys` (вектор элементов для инициализации кучи).

• Инициализирует переменные `d` и `heap`, где `heap` — это вектор, содержащий элементы.

- Запускает цикл, который вызывает функцию `sift_down` для каждого узла, начиная с последнего родительского узла и заканчивая корнем. Это позволяет построить d-кучу из неупорядоченного массива.

Функция `min_child`:

- Принимает индекс узла `id` и находит индекс минимального дочернего узла среди всех дочерних узлов данного узла.
- Вычисляет границы для дочерних узлов и сравнивает их значения, чтобы определить, какой из них минимален.
- Возвращает индекс дочернего узла с минимальным значением.

Функция `sift_down`:

- Принимает индекс узла `id` и восстанавливает свойства d-кучи, начиная с этого узла.
- Внутри цикла проверяет, есть ли дочерние узлы, и находит минимальный дочерний узел с помощью `min_child`.
- Если значение текущего узла больше значения минимального дочернего узла, они меняются местами, и процесс продолжается для нового узла, пока не будет восстановлено свойство кучи.

Функция `extract_min`:

- Извлекает минимальный элемент из кучи (корень).
- Сохраняет минимальный элемент, заменяет корень последним элементом в куче, уменьшает размер кучи и вызывает `sift_down` для восстановления свойств кучи.
- Возвращает извлеченный минимальный элемент.

Итог

Алгоритм сортировки `sort_d` работает следующим образом:

- Сначала создается d-куча из входного массива.
- Затем, используя метод извлечения минимального элемента, элементы извлекаются из кучи и добавляются в новый вектор, который будет отсортирован.
- В результате получается отсортированный массив, где элементы расположены в порядке возрастания.

3 Проведенные эксперименты

В данной лабораторной работе было проведено два эксперимента: суть первого заключался в том, чтобы понять как разные размеры массивов с различными характеристиками случайных чисел влияют на производительность алгоритмов сортировки, а второго - как изменения в генерации случайных чисел влияют на производительность сортировки для фиксированного размера массива, размер массива неизменен.

В каждом эксперименте массив создавался тремя разными способами: псевдослучайная генерация чисел, массив по убыванию, массив по возрастанию. Проведя эксперименты и проанализировав полученные данные имеем следующие графики:




Рис. 1. Первый эксперимент с массивом по возрастанию.




Рис. 2. Первый эксперимент с массивом по убыванию.




Рис. 3. Первый эксперимент с псевдослучайным массивом.

Во всех экспериментах обе линии показывают линейный рост времени выполнения при увеличении размера массива. Сортировка 3-кучей демонстрирует более низкое время выполнения по сравнению с сортировкой методом 4-слияния.

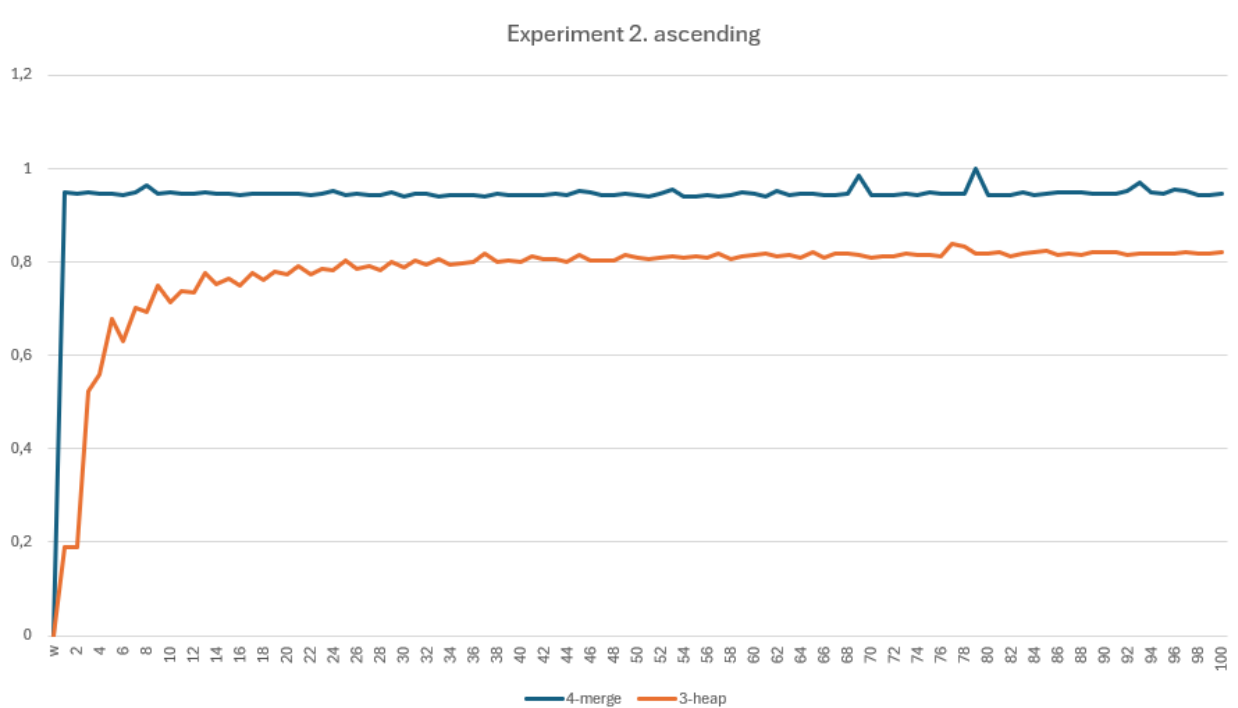


Рис. 4. Второй эксперимент с массивом по возрастанию.




Рис. 5. Второй эксперимент с массивом по убыванию.




Рис. 6. Второй эксперимент с псевдослучайным массивом.

По графикам видно, что во всех экспериментах выигрывает алгоритм сортировки на d-куче, так как он не тратит время на слияние массивов, а сразу достает нужный элемент из кучи.

4 Сравнение алгоритмов

1. Временная сложность

Временная сложность алгоритма сортировки к-слиянием $O(n \log n)$. В случае сортировки d-кучей временная сложность равна $O(n \log_d(n))$, зависит от значения d. Чем больше d, тем меньше количество уровней в куче, но большее количество дочерних узлов может увеличить время на операции с кучей.

2. Стабильность

Сортировка к-слиянием является стабильной, в отличие от сортировки d-кучей. Порядок равных элементов может измениться.

3. Использование памяти

Сортировка к-слиянием использует $O(\log n)$ дополнительной памяти для хранения стека вызовов рекурсии. В случае не-рекурсивной реализации может использовать $O(1)$ дополнительной памяти. Сортировка d-кучей использует $O(n)$ памяти для хранения кучи, так как все элементы должны быть в куче во время сортировки.

4. Простота реализации

Основная сложность в сортировке к-слиянием заключается в реализации рекурсивного разбиения на k частей и последующего слияния. Реализация сортировки d-кучей может быть более сложной из-за необходимости управления кучей и операций с ней (например, `sift_down` и `extract_min`).

5. Производительность на различных типах данных

Во всех случаях по производительности выиграла сортировка d-кучей. Однако сортировка к-слиянием является более стабильной.

5 Вывод

В ходе данной лабораторной работы были реализованы алгоритмы сортировки 4-слиянием и 3-кучей, проведены эксперименты, для анализа поведения и эффективности работы алгоритмов. Оба алгоритма имеют свои преимущества и недостатки. Сортировка 3-кучей оказалась быстрее, но сложнее в реализации. Сортировка 4-слиянием более устойчива к худшим случаям, но требует меньше памяти и может быть быстрее на практике. Опираясь на результаты экспериментов, можно сделать вывод, что сортировка 3-кучей, несмотря на сложную реализацию, выполняет свою работу эффективнее и стабильнее, чем сортировка 4-слиянием.